

# Problématique

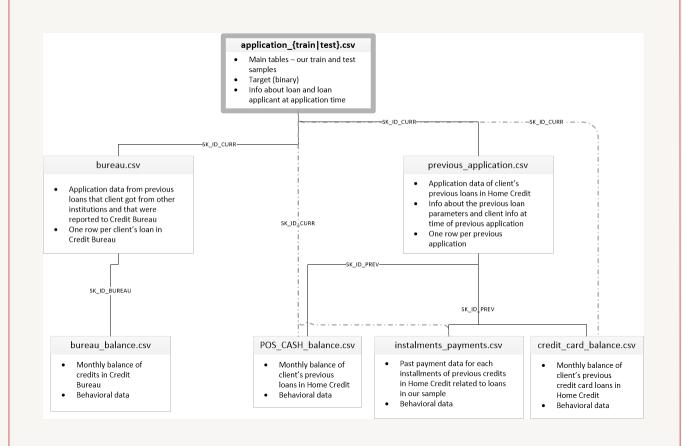


# NOS DEUX OBJECTIFS

# CRÉER UN MODELE DE SCORING

DEPLOYER LE MODELE

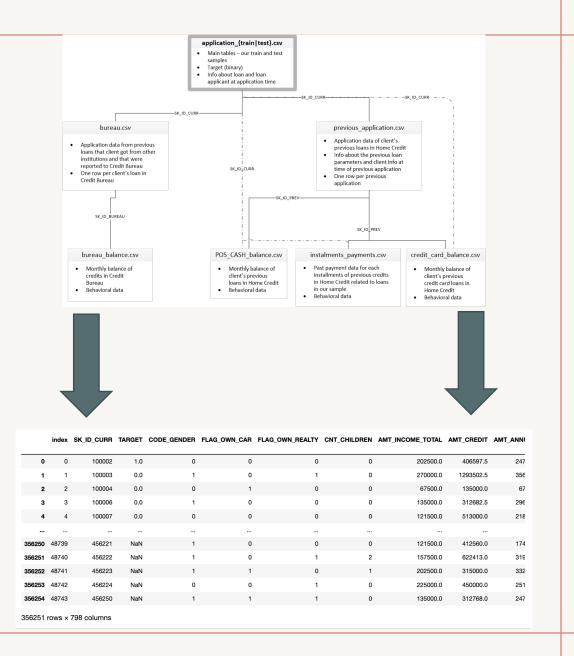
### Data



#### Kernel

#### Les avantages :

- Résumé une BDD relationnelle en une table
- Générer des kpis efficientes pour la prédiction



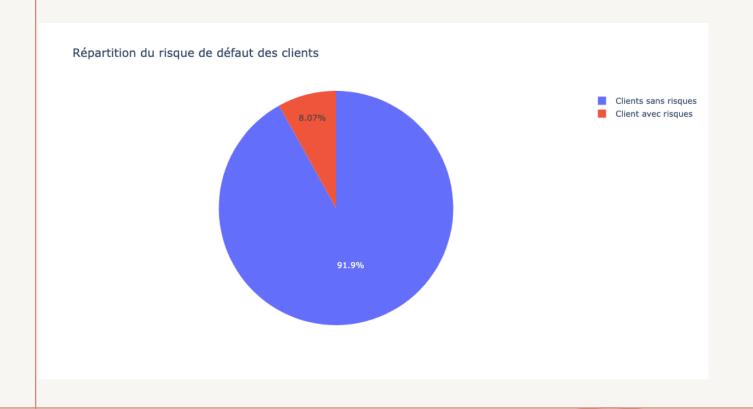
# Nettoyage

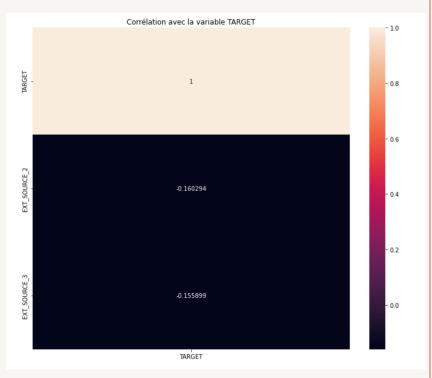
#### Suppression des colonnes trop incomplètes

```
print("Dimension initial du dataset :",df_train.shape)
    #df train.head()
 Dimension initial du dataset : (307507, 797)
1]: # Nettoyage en fonction des valeurs manquantes
    seuil=30
    #print((((df_train.isna().sum().sort_values()/df_train.shape[0])*100)>seuil).values.sum())
    # Colonnes avec plus de 30% de valeurs manquantes
    series_na=(((df_train.isna().sum().sort_values()/df_train.shape[0])*100)>30)
    liste_colonnes_na=list(series_na[series_na==False].index)
    # Liste des colonnes avec moins de 30% de valeurs manquantes
    #print(len(liste_colonnes_na))
    df_train=df_train[liste_colonnes_na]
    df_test=df_test[liste_colonnes_na]
    print("Dimension du dataset après suppression des colonnes incomplètes : ", df_train.shape)
    #df train.head()
 Dimension du dataset après suppression des colonnes incomplètes : (307507, 544)
```

#### Imputation par la valeur la plus fréquentes

# Analyse exploratoire





### Modélisation



# PATTERN DES PIPELINES TUNES

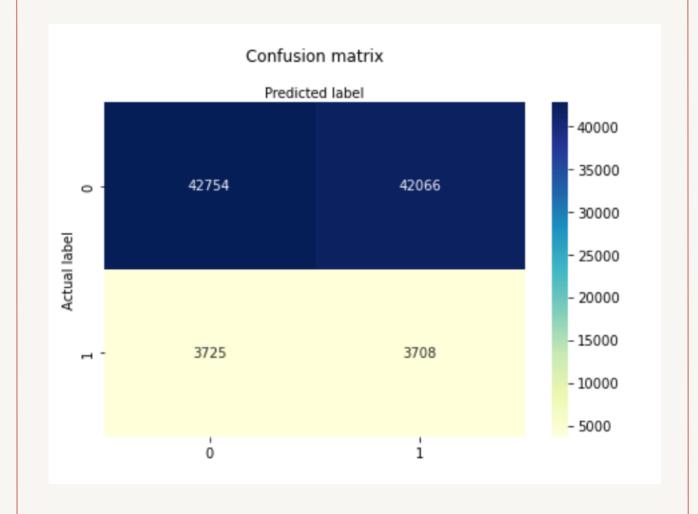


2/SMOTE

3/ MODELE

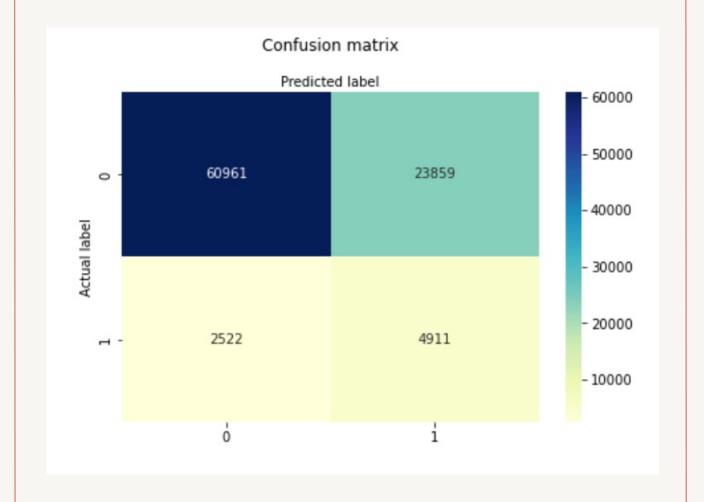
# Classifieur Dummy

- AUC = 0.5
- Recall = 0.5
- Accuracy = 0.5
- Pas de tuning



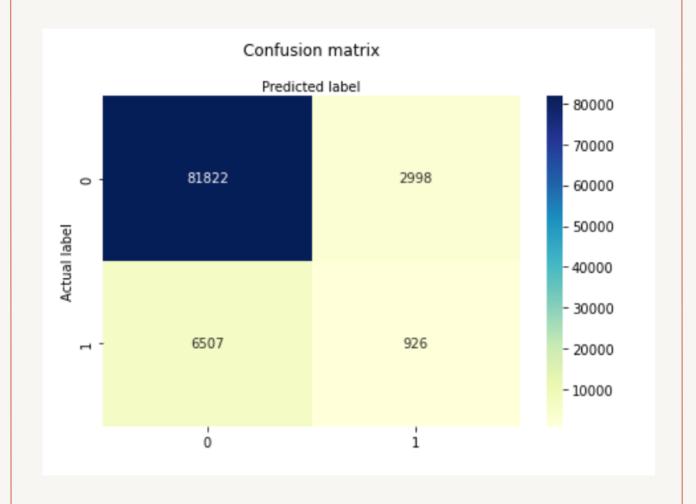
# Classifieur logistique

- AUC = 0.75
- Recall = 0.66
- Accuracy = 0.71
- Hyperparamètres : {'C': 1,'max\_iter': 300}



#### CLASSIFIEUR RANDOMFOREST

- AUC = 0.71
- Recall = 0.66
- Accuracy = 0.89
- Hyperparamètres :{'max\_depth':15, 'n\_estimators': 100}



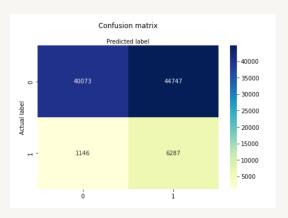
# Comparaison des modèles





# Optimisation du recall

- Tuning base sur un score fbeta
- Modification du seuil de decision proba





# Coefficient du modèle



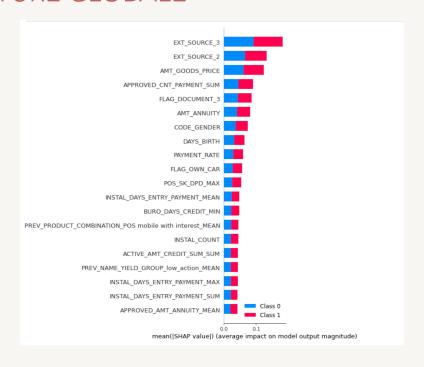


#### **SHAP**

#### FEATURE LOCALE



#### FEATURE GLOBALE



### Limites du modèle

ETHIQUE DISCUTABLE : CODE GENDER

CONTRAINTE DE TEMPS

# Application



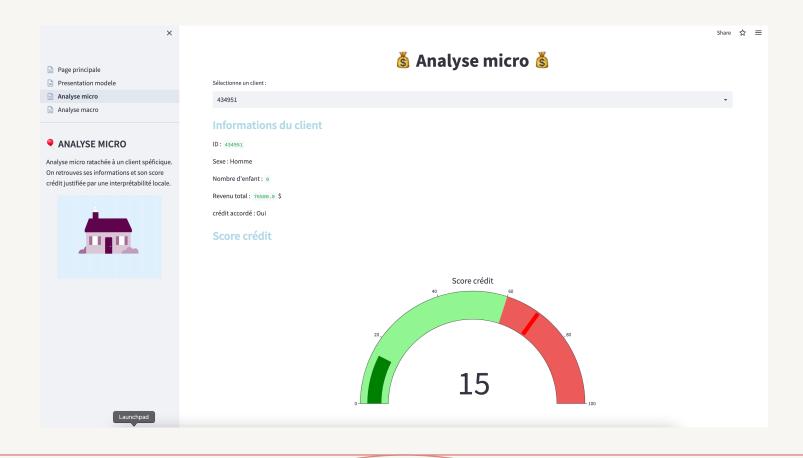
#### API

```
#Application
app = Flask(__name__)
@app.route('/')
def hello_world():
   return 'Bienvenue sur le modèle de scoring'
@app.route('/ID')
def ID():
    return 'ID du client'
@app.route('/ID/<id>', methods=['GET'])
def Prediction(id):
   try:
       ID=int(id) #100194
       index=df[df["SK_ID_CURR"]==ID].index.values[0]
       score=round(model.predict_proba(df.iloc[index:index+1,:])[0][1]*100) #368305
       defaut_credit=0
       if (score>70) : defaut_credit=1
       return jsonify({'Score' : score, "Defaut_credit" : defaut_credit})
       return jsonify({"erreur" : S3_connexion})
if __name__ == '__main__':
   app.run()
```

```
← → C api-score-credit.herokuapp.com/ID/368305

{"Defaut_credit":1, "Score":80}
```

### Dashboard



## Dashboard

